

AI 使用说明

学生：王静怡

学号：032402101

课程：2025-2026 学年第 2 学期《数据分析与可视化》期末考试

1. 使用的 AI 工具

- Claude Code** (Anthropic Claude 系列模型)：用于代码辅助、报错排查、图表优化和文字表达整理。
- GitHub Copilot** (VS Code 插件)：用于代码补全和函数签名提示。

2. 使用 AI 的具体环节

环节	具体说明
数据清洗函数编写	从 面积、总价、均价、楼层、建造时间、户型 等文本字段中提取数值或分类变量时，向 AI 询问正则表达式的写法和 <code>pd.Series.apply()</code> 的用法。例如 <code>extract_year()</code> 、 <code>extract_floor_type()</code> 、 <code>extract_layout()</code> 等函数。
解释报错	运行过程中遇到 <code>KeyError</code> 、 <code>SettingWithCopyWarning</code> 、中文字体渲染失败（ <code>findfont: Font family not found</code> ）等报错时，将报错信息粘贴给 AI 分析原因并获取修复建议。
查询 pandas/matplotlib/seaborn 函数用法	包括 <code>pd.pivot_table()</code> 参数设置、 <code>sns.catplot()</code> 的 <code>col</code> 和 <code>order</code> 参数、 <code>sns.FacetGrid</code> 的 <code>map_dataframe</code> 用法、 <code>plt.subplots()</code> 子图布局、 <code>mpl_toolkits.mplot3d</code> 3D 绘图 API 等。
优化图表代码	8 张可视化图表中，部分复杂图表（如图表 5 的 Mantel 连线图、图表 7 的 3D 透明分层曲面图、图表 6 的 3D 柱状热力图）的绘制代码向 AI 请教了实现思路和参数调整建议。
配色方案设计	向 AI 请教如何设计“清新、不刺眼、适合学术报告”的马卡龙配色方案，最终确定了一组低饱和度的全局颜色变量（ <code>FRESH_BLUE</code> 、 <code>FRESH_GREEN</code> 等）。
整理文字表达	报告中的摘要、分析目标、统计发现和主要结论等文字段落，部分初稿后请 AI 帮助润色、精简或调整逻辑结构，使表达更加清晰流畅。

3. 主要提问内容或提示词摘要

以下是考试过程中向 AI 工具提出的部分典型问题（凭记忆整理）：

1. 数据清洗相关：

1. "pandas 怎么把一个包含'103m²'这种带单位字符串的列转成浮点数？"
3. "写一个正则表达式，从'中层(共31层)'这种字符串里分别提取楼层位置和总层数"
4. "pandas 的 apply 函数怎么返回多个列？"

1. 可视化相关：

2. "matplotlib 怎么让中文字体正常显示？SimHei 字体怎么配置？"
3. "seaborn 的 catplot 怎么按市区排序箱线图，同时按房龄分面？"
4. "怎么用 matplotlib 画 3D 散点图？颜色按市区区分"
5. "Pearson 相关系数矩阵热力图怎么画？旁边再加一个 Mantel test 的连线图"
6. "3D 柱状图 (bar3d) 的每个柱子怎么按高度映射颜色？"
7. "3D 曲面图怎么让不同市区用不同颜色透明分层显示？"

1. 统计分析相关：

2. "pandas 的 pivot_table 和 crosstab 有什么区别？分别什么时候用？"
3. "IQR 方法检测异常值的原理和代码怎么写？"
4. "eta² (效应量) 怎么计算？"

1. 文字润色相关：

2. "帮我把这段数据分析摘要改得更学术一些"
3. "这段结论能不能分成几个要点，逻辑更清晰？"

4. 我对 AI 输出做了哪些检查、修改或取舍

1. **代码逐行验证**：AI 生成的代码我都会在 Notebook 中逐行运行测试，确认结果符合预期后才保留。例如，数据清洗函数生成后，我会用 `value_counts()`、`describe()` 等方法验证提取结果是否与原字段一致。
1. **正则表达式调整**：AI 给出的正则表达式有时不能覆盖所有边界情况（如部分楼层字段格式不统一），我根据实际数据中的异常格式手动补充了条件判断和 fallback 逻辑。
1. **图表参数微调**：AI 给出的图表代码只是一个起点。我根据实际数据范围手动调整了轴范围（如 `set_xlim`、`set_ylim`）、柱子宽度、视角角度（3D 图的 `view_init`）、颜色映射（`vmin / vmax`）和图例位置等参数，确保图表可读性和美观性。

1. **配色方案迭代**：AI 给出的初始配色在实际图表中略显灰暗，我经过几轮调整（提高亮度、降低饱和度）才确定了最终使用的 7 色马卡龙方案。
1. **统计分析逻辑把关**：Mantel 检验、eta² 效应量等统计方法的使用是否恰当，我参考了课件和教材确认后才采用，并非完全依赖 AI。
1. **文字内容审核**：AI 润色后的文字我会通读检查，确保没有 AI 凭空编造的数据或结论，所有数字和发现均来自我自己的分析结果。
1. **舍弃不合适的建议**：AI 曾建议使用 `plotly` 交互式图表替代 `matplotlib` 的静态 3D 图，但考虑到考试要求中可能需要展示静态图表，我最终选择保留 `matplotlib` 方案。AI 也曾建议删除所有异常值，但我判断豪宅/大户型是真实存在的房源，不宜简单删除，因此仅在图表中裁剪显示范围。

5. 哪些分析结论是我根据数据自行判断得到的

以下核心分析结论均由我在观察数据和图表后独立判断得出，AI 未参与：

结论	判断依据
鼓楼区抗跌性最强 ：从 2 年内到 10 年以上房龄，鼓楼区均价降幅仅约 21%，远低于闽侯（约 50%）和仓山（约 36%）	观察图表 2 箱线图和图表 7 3D 曲面图的趋势，结合分组统计数据
中层"黄金楼层"溢价在核心区最明显	观察图表 6 3D 柱状图中鼓楼区中层柱显著高于低/高层，而外围区差异较小
仓山、晋安是刚需主战场 ：两区合计占房源 70%，均价处于全市中等偏下	根据图表 1 各区房源数量和均价统计自行归纳
户型结构趋于紧凑 ：2 室及以下小户型在 2 年内新房中占比高于老房	观察图表 8 堆叠百分比柱状图得出的趋势判断
远郊县（闽清、永泰）样本量不足，结论需谨慎	自己在数据质量检查阶段发现样本量过少
数据仅来自安居客单一平台，代表性有限	根据数据来源字段和常识判断的数据局限性
面积-总价-均价的三维关系 ：大面积低单价 vs 小面积高单价（学区房）的分化模式	观察图表 3 3D 散点图旋转视角后得出的洞察

总结：AI 在本报告中主要承担了"代码助手"和"文字编辑"的角色——帮助我高效编写数据清洗和可视化代码、优化文字表达。而分析框架的设计、统计方法的选择、图表结论的解读、数据局限的判断以及对购房者的建议，均由我基于课堂所学知识和独立数据探索得出。